
TELCO CUSTOMER CHURN CLASSIFICATION

SAUSAU projektni zadatak

DIMITRIJE LAZIĆ RA 92/2023
2026

Opis zadatka

Cilj ovog projekta je kreiranje klasifikacionog modela uz pomoć mašinskog učenja koji je sposoban da predvidi da li će korisnik telekomunikacione usluge raskinuti ugovor (churn) ili ostati (no churn), na osnovu demografskih, uslužnih i fakturačkih karakteristika.

Rad na projektu podrazumeva kompletan postupak čišćenja, skaliranja i preprocesiranja skupa podataka, kako bi bio pogodan za primenu u mašinskom učenju, zatim eksplorativnu analizu podataka (EDA) gde su utvrđene zavisnosti između atributa. Nakon toga se prelazi na sam postupak mašinskog učenja, gde je isprobano više različitih metoda ne bi li se utvrdio najpogodniji model za dati problem koji se kasnije pušta u produkciju, gde je omogućeno korišćenje modela od strane korisnika uz pomoć Streamlit aplikacije.

Na kraju su izvedeni zaključci proistekli iz rada na projektu, kao i predlozi za dalji rad i usavršavanje modela.

Struktura projekta

```
projekat/
├── data/
│   ├── raw/                # originalni telco_data.csv
│   └── processed/          # preprocesirani set podataka
├── models/                 # exportovani modeli (.pkl) i scaler
├── notebooks/
│   └── 01_eda.ipynb        # EDA, preprocesiranje, modelovanje
├── reports/
│   └── figures/            # grafici iz EDA i evaluacije
├── src/
│   └── churn/
│       ├── __init__.py
│       ├── preprocessing.py # priprema i enkodiranje podataka
│       ├── model.py         # treniranje XGBoost modela
│       ├── evaluate.py      # metrike i konfuziona matrica
│       └── predict.py       # predikcija na novim podacima
├── app.py                  # Streamlit aplikacija
├── pyproject.toml
└── README.md
```

Postupak


1. Preprocesiranje

Na početku rada izvršeno je pripremanje skupa podataka za obuku modela. Kako računar radi samo sa brojevima, bilo je potrebno konvertovati sve tipove podataka koje nisu brojevi u numeričke tipove. Takođe su izbačeni redovi koji sadrže prazna polja (null vrednosti). Tako je, između ostalog, realizovana:

- Konverzija TotalCharges iz string u numerički tip i uklanjanje 11 praznih (null) vrednosti
- Uklanjanje customerID kolona (Atribut customerID ne sadrži informacije koje bi bile relevantne modelu pri donošenju odluke, stoga je uklonjen)
- Binarno enkodiranje Yes/No kolona
- One-Hot Encoding za Contract, InternetService, PaymentMethod
 - One-Hot Encoding predstavlja tip enkodiranja gde se za svako obeležje koje može uzeti prebrojivo mnogo različitih vrednosti pravi novo obeležje za svaku vrednost ponaosob koje može uzeti vrednost 1 ili 0.
- Skaliranje je izvršeno uz pomoć StandardScaler, koji skalira vrednosti na srednju vrednost 0 i standardnu devijaciju 1.

2. EDA


- Dataset ima 7043 redova i 21 kolonu




- Ciljna promenljiva je loše balansirana: 73.5% No Churn, 26.5% Churn. Iz ovoga se odmah može zaključiti da će potencijalan problem predstavljati mali broj Churn primera, jer model neće imati dovoljno primera da nauči obrasce koji karakterišu korisnika koji će raskinuti ugovor.

Dimitrije Lazić RA 92/2023
TELCO CUSTOMER CHURN CLASSIFICATION


- Ključni nalazi:




- Sa drugog violin plot-a vidimo da korisnici koji odlaze u proseku imaju veći mesečni trošak što definitivno doprinosi njihovom nezadovoljstvu uslugom.




- Korisnici sa kraćim tenure-om češće odlaze. Ovo je logično jer korisnici koji su kraće sa provajderom se manje identifikuju sa istim i nisu stekli neko poverenje koje bi ih nateralo da ostanu.



- Month-to-month ugovor ima najvišu stopu odlaska. To je najmanje obavezujući tip ugovora jer nije naveden tačan datum prestanka pa korisnici osećaju veću slobodu da raskinu ugovor ako nisu zadovoljni uslugom.



- Fiber optic korisnici odlaze češće od DSL. Verovatno jer je to skuplja opcija pa korisnici nisu zadovoljni kvalitetom koji dobijaju za uloženi novac.



- Electronic check korisnici imaju veći churn rate (Electronic check ne uzrokuje churn, ali korisnici koji ga koriste imaju profil koji je skloniji churnu; primetiti razliku između korelacije i uzročnosti)

3. Modelovanje i izbor metrike

Odabir je pao na ova četiri modela:

Model	F1 (Churn)	Recall (churn)	AUC-ROC
Logistička regresija	0.62	0.79	0.8418
Random Forest	0.59	0.63	0.8217
XGBoost	0.60	0.68	0.8197
SVM	0.59	0.82	0.7927

Pri obuci su postavljeni parametri `class_weight` na 'balanced' i `scale_pos_weight` (specifično za XGBoost) kako bi greška na manjinskoj klasi bila skuplja, što nam je i bitno u ovom primeru.

Što se metrike tiče izabrane su F1 score, Recall i AUC-ROC kao glavna metrika.

Recall score je bitan više za interpretaciju jer predstavlja procenat korisnika koji odlaze a koje je model uspešno “uhvatio”. Ovo je bitno jer je propušten odlazeći korisnik skuplji nego korisnik koji je označen da odlazi a u stvari će ostati (False Positive je mnogo prihvatljiviji u ovom kontekstu nego False Negative).

F1 score predstavlja harmonijsku sredinu između Precision i Recall, to je jedan broj koji pokazuje koliko je model dobar u obe metrike (korišćen kao referenca sa kojom se porede ostale metrike i kao metrika po kojoj će se kasnije raditi podešavanje hiperparametara).

AUC-ROC (Area Under Curve) predstavlja metriku koja pokazuje koliko dobro model razdvaja dve klase bez obzira na prag odlučivanja, zato je mnogo teži za lažiranje od npr. Recall i predstavlja odličnu opciju za glavnu metriku. AUC-ROC je zapravo površina ispod krive koje predstavlja odnos True Positive rate i False Positive rate za različite pragove (ne zavisi od toga gde se “povuče linija” za da/ne).

Vidi se da logistička regresija daje rezultate uporedive sa u opštem slučaju mnogo sposobnijim i svestranijim ansambl metodama i Support Vector Machine. Ovo je prva naznaka da je odnos atributa i ciljne promenljive poprilično linearan pa i linearan model uspeva da uhvati obrasce.


4. Podešavanje hiperparametara

Hiperparametri su podešeni koristeći GridSearchCV sa 5-fold unakrsnom validacijom. Algoritam podešava hiperparametre za ansambl metode i SVM nasumično, isprobavajući sve kombinacije tako što ih po 5 puta trenira i testira, svaki put na različitim podskupovima podataka. Na kraju najbolji model se ponovo trenira i testira na skupu koji do sada nije viđen – sprečeno je curenje podataka.

Model	F1 (Churn)	Recall (churn)	AUC-ROC
Random Forest (tuned)	0.63	0.78	0.8413
XGBoost (tuned)	0.62	0.79	0.8448
SVM (tuned)	0.62	0.80	0.8326

Poređenjem ove tabele sa prethodnom dolazimo do zaključka da je XGBoost sa podešenim hiperparametrima najbolji u glavnoj metrici (AUC-ROC).

5. Feature Importance





Analiza važnosti atributa je urađena uz pomoć XGBoost modela koji, nakon što je treniran, vraća `feature_importances`, što je zapravo normalizovani gain, a to je metrika koja meri koliko se greška smanji kada se konkretan atribut koristi za podelu kod stabla odlučivanja, sumirano kroz sva stabla. Vidimo da najvažniji atribut uzima skoro pola ukupne važnosti svih obeležja, što predstavlja ozbiljan nedostatak u skupu podataka jer nemamo drugih u istoj meri važnih atributa, pa se odlučivanje u određenoj meri svodi na binarno “ako korisnik ima month-to-month ugovor onda će otići, u suprotnom ne”.

Top atributi:

- **Contract_Month-to-month (0.48)** — ubedljivo najvažniji atribut, skoro 50% ukupne važnosti. Korisnici bez dugoročnog ugovora odlaze daleko češće jer nema nikakve obaveze koja ih zadržava.
- **InternetService_Fiber optic (0.10)** — drugi najvažniji. Fiber optic korisnici su nezadovoljniji, verovatno zbog više cene u odnosu na očekivani kvalitet.
- **Contract_Two year (0.05)** — negativno korelisan sa churnom, dvogodišnji ugovor jako zadržava korisnike.
- **InternetService_No (0.05)** — korisnici bez interneta retko odlaze, verovatno jer koriste samo telefonsku uslugu koja je jeftinija.
- **PaymentMethod_Electronic check (0.04)** — potvrđuje ono što se vidi u EDA, a to je da su electronic check korisnici skloniji churnu.

Dimitrije Lazić RA 92/2023

TELCO CUSTOMER CHURN CLASSIFICATION



Pored XGBoost feature importance urađeni i ANOVA F-test i chi-square test radi statističke potpore nalazima dobijenim sa XGBoost algoritmom. Vidimo da se statističke analize u značajnoj meri poklapaju sa XGBoost feature importance analizom.

XGBoost model sa samo 9 najvažnijih atributa postiže AUC-ROC 0.8426, što je zanemarljiva razlika u odnosu na model sa svim atributima (0.8448), te je ovaj model upravo taj koji je pušten u produkciju, jer manji broj atributa čini proračun lakšim i jeftinijim i smanjuje rizik od preprilagođavanja (manja šansa da model krene da uči šum iz podataka).

6. Deployment

Streamlit aplikacijom omogućen unos podataka o korisniku (samo 9 najvažnijih atributa) i predviđanje verovatnoće raskidanja ugovora (churn) u realnom vremenu.

Telco Customer Churn Predictor

Unesite podatke o korisniku da biste predvideli da li će otkazati uslugu.

Podaci o korisniku

Tenure (meseci)

12

Način plaćanja

Electronic check

Mesečni trošak (\$)

50

Online zaštita

Yes

Tip ugovora

Month-to-month

Streaming filmovi

Yes

Internet usluga

DSL

Predvidi

Rezultat

⚠ Korisnik će verovatno otkazati uslugu!

Verovatnoća chorna

53.4%

Rezultati i zaključci

- XGBoost sa podešenim hiperparametrima je najbolji model (AUC-ROC 0.8448)
- Najvažniji faktor je tip ugovora (month-to-month korisnici odlaze najčešće)
- Redukcija na 9 atributa ne utiče značajno na performanse (AUC-ROC: 0.8448 vs 0.8426), logičnije je odabrati jednostavniji model
- Dataset je imbalanced što ograničava Precision za Churn klasu (~0.51)
- Korisnici koji odlaze imaju mali TotalCharges jer su kratko bili sa kompanijom što je direktna posledica kratkog tenure-a, a ne nužno uzrok chuna sam po sebi.
- Atributi nisu dovoljno "jaki", većina kolona su kategorijske Yes/No vrednosti koje nose relativno malo informacija. Nema npr. podataka o broju poziva korisničkoj službi, broju reklamacija, ili istoriji plaćanja, a to su faktori koji bi značajno poboljšali model.
- Logistička regresija daje rezultate koji su uporedivi sa složenijim modelima, što znači da su odnosi u podacima pretežno linearni.

Preporuke za unapređenje

- Dodati više atributa (broj kontakata sa podrškom, istorija reklamacija)
- Primeniti SMOTE (tehnika za sintetičko generisanje novih Churn primera) za bolji tretman imbalanced dataseta.
 - SMOTE tehnika generiše nove primere tako što izabere primerak manjinske klase, odredi k najbližih suseda u prostoru atributa, od njih izabere jedan nasumičan, pa zatim izabere nasumičnu tačku na liniji koja spaja ta dva primera u prostoru atributa koja će predstavljati nov primerak manjinske klase.
- Prikupiti duži vremenski period podataka

Pokretanje aplikacije

uv run streamlit run app.py